

Análisis Matemático para Inteligencia Artificial

Verónica Pastor (vpastor@fi.uba.ar),
Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

4/11/2022

El mundo del Data Science y las competencias de Machine Learning cobraron mucha relevancia con la [competencia de Netflix](#), que prometía **1M USD** a quien pudiera obtener una performance de un 10% por sobre su algoritmo de base para el problema de recomendación de películas.

En este contexto surgió una nueva variante de modelo en base a factorización de matrices.

¿Lo interesante? Con las dos clases de AM ya nos alcanza para entenderlo!

¿Por qué funciona la inversa? (1/2)

Demostremos que:

Si $A \in \mathbb{R}^{n \times n}$ es una matriz definida positiva, entonces es invertible:

Dem.: (por método del absurdo)

Supongamos que el determinante de A es cero, y llegaremos a una solución absurda.

Si $\det(A) = 0$ y queremos resolver un sistema $Ax = 0$ significa que además de la solución trivial hay infinitas soluciones, es decir $\text{rango}(A) < n$, entonces

$$\exists \tilde{x} \neq 0 : A\tilde{x} = 0 \Rightarrow \tilde{x}^T A \tilde{x} = \tilde{x}^T 0 = 0$$

y entonces no se cumple que $\tilde{x}^T A \tilde{x} > 0$.

$$u \left(\underbrace{\sum_{j \in \mathcal{O}_j} \underbrace{v_j v_j^T}_{k \times k}}_{\substack{A \\ k \times k}} + \lambda I_k \right) = \sum_{j \in \mathcal{O}_i} r_{ij} \underbrace{v_j}_{k \times k}$$

$u_{1 \times k} \cdot \underbrace{A}_{k \times k}$ es def. positiva?

$A^{-1} A^{-1}$

$XA = b$
 $(AX)^T = \tilde{b}$

¿Por qué funciona la inversa? (2/2)

Demostremos que:

$A = \underbrace{x \cdot x^T}_{\text{simétrica}} + \lambda I_k$ es definida positiva, es decir, $y^T A y > 0, \forall y \in \mathbb{R}^k - \{0\}$

A es simétrica?

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix} + \begin{pmatrix} \lambda & 0 & \dots & 0 \\ 0 & \lambda & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda \end{pmatrix} = \begin{pmatrix} a_{11} + \lambda & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} + \lambda & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} + \lambda \end{pmatrix}$$

simétrica

Suma de matrices simétricas es simétrica

Dem.: Sea $y \in \mathbb{R}^k - \{0\}$

$$y^T (x \cdot x^T + \lambda I_k) y = \underbrace{(y^T x) x^T y}_{\text{p.i. sim. (esp. vectorial)}} + \underbrace{y^T \lambda I_k y}_{\text{p.i. sim. (esp. vectorial)}}$$

(recordemos que el p.i. es $\langle u, v \rangle = u^T v$), prop. asociativa

$$\langle y, x \rangle \langle x, y \rangle + \lambda \langle y, y \rangle = \langle x, y \rangle^2 + \lambda \|y\|^2 > 0.$$

parámetro del modelo $\lambda > 0$

$\therefore \underline{x \cdot x^T + \lambda I_k}$ es definida positiva.

p.i. conmutativo (en \mathbb{R}^k)

Proyección Ortogonal

Proyección

Sea \mathbb{V} un EV y $S \subset \mathbb{V}$ un SEV. Una transformación lineal $\Pi : \mathbb{V} \rightarrow S$ es una proyección si $\Pi^2 = \Pi \circ \Pi = \Pi$ *idempotente*. Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia: $[\Pi]^2 = [\Pi]$.


Proyección Ortogonal

Dado \mathbb{V} un EV con p.i. y $S \subset \mathbb{V}$ un SEV, el objetivo es dado $v \in \mathbb{V}$ hallar $\tilde{v} \in S$ que sea "lo más parecido posible" a v .

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

Además vale que $\langle v - \tilde{v}, s \rangle = 0, \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



Teorema de proyección

Sea \mathbb{V} un EV de dimensión finita con p.i. $\langle \cdot, \cdot \rangle$, S un SEV. Dado $v \in \mathbb{V}$ existe un único $\tilde{v} \in S$ tal que

$$||v - \tilde{v}|| \leq ||v - u||, \quad \forall u \in \mathbb{V}$$

¿Cómo hallar la proyección?

$s_i \in V$ there n comp.

Sea \mathbb{V} un EV de dimensión n con p.i. $\langle \cdot, \cdot \rangle$, y $S \subset \mathbb{V}$ un SEV, $\dim(S) = m \geq 1$, y sea $B = \{s_1, \dots, s_m\}$ una BON de S . Buscamos encontrar la proyección de $\tilde{v} \in S$ de $v \in \mathbb{V}$ ($\tilde{v} = \Pi_S(v)$).

Como $\tilde{v} \in S$, $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$ busco los coeficientes que minimizan $\|v - \sum_{i=1}^m \alpha_i s_i\|$. El problema puede escribirse como:

$\tilde{v} = \Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha$, $B = [s_1, \dots, s_m]$, $\alpha = [\alpha_1, \dots, \alpha_m]^T$
 $n \times 1$ $n \times m$ $m \times 1$
 $\tilde{v} = B\alpha$
 $n \times 1$ $n \times m$ $m \times 1$
 B^{-1}

¿Cómo hallar la proyección?

Como por definición $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$, debo resolver el siguiente sistema de ecuaciones:

$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix} (v - B\alpha) = 0$$

$$\underbrace{B^T(v - B\alpha) = 0}_{B^T v - B^T B \alpha = 0} \Leftrightarrow \underbrace{B^T v}_{\substack{\text{BON} \\ \tilde{v} = \Pi_S(v)}} = \underbrace{B^T B \alpha}_{\substack{\text{BON} \\ \tilde{v} = \Pi_S(v)}} \Leftrightarrow \alpha = \underbrace{(B^T B)^{-1} B^T v}_{\substack{\text{BON} \\ \tilde{v} = \Pi_S(v)}} \Rightarrow (B^{-1})^T = (B^T)^{-1}$$

Observación: Si \underline{B} es una BON entonces $P_{\Pi_S} = \underline{B} B^T$.

$$\|v\| = v^T v = 1$$

Aplicación: Cuadrados Mínimos

Supongamos que tenemos un sistema sobredeterminado de la forma:

$$Ab = y, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^n, \quad y \in \mathbb{R}^m, \quad m > n.$$

b es la solución de cuadrados mínimos

Como $m > n$, puede que no exista b que satisfaga todas las m ecuaciones, entonces busco la solución que más se acerque (busco $\text{Proy}_{\text{Col}(A)} y$)

$$b = (A^T A)^{-1} A^T y \Rightarrow P = A(A^T A)^{-1} A^T$$

MATRIZ de la
T.L. Proyección
ortogonal
MATRIZ de $m \times m$

proyección
sobre S
donde S
es sub. $\text{Col}(A)$

Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!