

# Análisis Matemático para Inteligencia Artificial

Verónica Pastor (vpastor@fi.uba.ar),  
Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

Clase 3

El mundo del Data Science y las competencias de Machine Learning cobraron mucha relevancia con la [competencia de Netflix](#), que prometía **1M USD** a quien pudiera obtener una performance de un 10% por sobre su algoritmo de base para el problema de recomendación de películas.

En este contexto surgió una nueva variante de modelo en base a factorización de matrices.

¿Lo interesante? Con las dos clases de AM ya nos alcanza para entenderlo!

## ¿Por qué funciona la inversa? (1/2)

Demostremos que:

$$x^T A x > 0 \quad \forall x \in \mathbb{R}^n \setminus \{0\}$$

Si  $A \in \mathbb{R}^{n \times n}$  es una matriz definida positiva, entonces es invertible:

Dem.: (por método del absurdo)

Supongamos que el determinante de  $A$  es cero, y llegaremos a una solución absurda.

$$\det(A) = 0 \Leftrightarrow \nexists A^{-1} \Leftrightarrow \exists \tilde{x} \neq 0_v / A \tilde{x} = 0$$

Si  $\det(A) = 0$  y queremos resolver un sistema  $Ax = 0$  significa que además de la solución trivial hay infinitas soluciones, es decir  $\text{rango}(A) < n$ , entonces

$$\exists \tilde{x} \neq 0 : A \tilde{x} = 0 \Rightarrow \tilde{x}^T A \tilde{x} = \tilde{x}^T 0 = 0$$

y entonces no se cumple que  $\tilde{x}^T A \tilde{x} > 0$ .

$$\cup \quad A \text{ no invertible} \Rightarrow A \text{ NO def. +}$$



$$A \text{ def. +} \Rightarrow A \text{ invertible}$$

## ¿Por qué funciona la inversa? (2/2)

Demostremos que:

$A = x \cdot x^T + \lambda I_k$  es definida positiva, es decir,  $y^T A y > 0$ ,  $\forall y \in \mathbb{R}^k - \{0\}$

$$= \sum x_i x_i^T + \lambda I_k = x_1 \cdot x_1^T + x_2 \cdot x_2^T + \dots + x_j \cdot x_j^T + \lambda I_k$$

Dem.: Sea  $y \in \mathbb{R}^k - \{0\}$

$$y^T (x \cdot x^T + \lambda I_k) y = \underbrace{y^T x}_{< y, x >} \underbrace{x^T y}_{< x, y >} + y^T \lambda I_k y$$

(recordemos que el p.i. es  $< u, v > = u^T v$ ), prop. asociativa,

$$< y, x > < x, y > + \lambda < y, y > = \underbrace{< x, y >^2}_{\geq 0} + \underbrace{\lambda ||y||^2}_{\geq 0} > 0.$$

$\therefore x \cdot x^T + \lambda I_k$  es definida positiva.

$\lambda \in \mathbb{R}^+$   
construcción  
 $y \neq 0$

# Proyección Ortogonal

## Proyección

Sea  $\mathbb{V}$  un EV y  $S \subset \mathbb{V}$  un SEV. Una transformación lineal  $\Pi : \mathbb{V} \rightarrow S$  es una proyección si  $\Pi^2 = \Pi \circ \Pi = \Pi$

Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia:  $[\Pi]^2 = [\Pi]$ .

## Proyección Ortogonal


Dado  $\mathbb{V}$  un EV con p.i. y  $S \subset \mathbb{V}$  un SEV, el objetivo es dado  $v \in \mathbb{V}$  hallar  $\tilde{v} \in S$  que sea “lo más parecido posible” a  $v$ .

$$v - \tilde{v} \in S^\perp$$

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

Además vale que  $\langle v - \tilde{v}, s \rangle = 0, \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



# Teorema de proyección

Sea  $\mathbb{V}$  un EV de dimensión finita con p.i.  $\langle \cdot, \cdot \rangle$ ,  $S$  un SEV. Dado  $v \in \mathbb{V}$  existe un único  $\tilde{v} \in S$  tal que

$$\exists ! \quad \|v - \tilde{v}\| \leq \|v - u\|, \quad \forall u \in S$$

*la proy. ortogonal es única  $\forall v$*

¿Cómo hallar la proyección?

Sea  $\mathbb{V}$  un EV de dimensión  $n$  con p.i.  $\langle \cdot, \cdot \rangle$ , y  $S \subset \mathbb{V}$  un SEV,  $\dim(S) = m \geq 1$ , y sea  $B = \{s_1, \dots, s_m\}$  una BON de  $S$ . Buscamos encontrar la proyección de  $\tilde{v} \in S$  de  $v \in \mathbb{V}$  ( $\tilde{v} = \Pi_S(v)$ ).

Como  $\tilde{v} \in S$ ,  $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$  busco los coeficientes que minimizan  $\|v - \sum_{i=1}^m \alpha_i s_i\|$ . El problema puede escribirse como:

$$\tilde{v} = \Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha, \quad B = [s_1, \dots, s_m], \quad \alpha = [\alpha_1, \dots, \alpha_m]^T$$

*x y  $\tilde{v}, v \in \mathbb{R}^n$*   *$B = \begin{pmatrix} | & | & \dots & | \\ s_1 & s_2 & \dots & s_m \\ | & | & \dots & | \end{pmatrix} \in \mathbb{R}^{n \times m}$*   *$\alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix} \in \mathbb{R}^m$*

## ¿Cómo hallar la proyección?

Como por definición  $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$ , debo resolver el siguiente sistema de ecuaciones:

$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \overbrace{\begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix}}^{B^T} (v - B\alpha) = 0$$

$$B^T(v - B\alpha) = 0 \Leftrightarrow B^T v = B^T B\alpha \Leftrightarrow \alpha = (B^T B)^{-1} B^T v$$

$$\Pi_S = B(B^T B)^{-1} B^T$$

$$\tilde{v} = B \cdot \underbrace{d = B \cdot (B^T B)^{-1} \cdot B^T}_{\Pi_S} v$$

**Observación:** Si  $B$  es una BON entonces  $P_{\Pi_S} = BB^T$ .

# Aplicación: Cuadrados Mínimos



Supongamos que tenemos un sistema sobredeterminado de la forma:  $Ab = y$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^n$ ,  $y \in \mathbb{R}^m$ ,  $m > n$ .  $s \in S$   $v \in V$   
 $\min \|\tilde{y} - y\|$

$$S = \text{Col}(A)$$

$b$  es la solución de cuadrados mínimos

$$A \cdot \hat{b} = \tilde{y}$$

Como  $m > n$ , puede que no exista  $b$  que satisfaga todas las  $m$  ecuaciones, entonces busco la solución que más se acerque (busco  $\text{Proy}_{\text{Col}(A)} y$ )

$$b = \underbrace{(A^T A)^{-1} A^T}_{\hat{\beta}} y \Rightarrow P = \underbrace{A(A^T A)^{-1} A^T}_{\Pi_S}$$

$$\hat{y} = B \cdot x = A \cdot \hat{\beta}$$



Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!