

Análisis Matemático para Inteligencia Artificial

Verónica Pastor (vpastor@fi.uba.ar),
Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

18/3/2022

El mundo del Data Science y las competencias de Machine Learning cobraron mucha relevancia con la [competencia de Netflix](#), que prometía **1M USD** a quien pudiera obtener una performance de un 10% por sobre su algoritmo de base para el problema de recomendación de películas.

En este contexto surgió una nueva variante de modelo en base a factorización de matrices.

¿Lo interesante? Con las dos clases de AM ya nos alcanza para entenderlo!

¿Por qué funciona la inversa? (1/2)

Demostremos que:

→ Asimétrica

$$y^T A y > 0 \quad \forall y \neq 0$$

→ Si $A \in \mathbb{R}^{n \times n}$ es una matriz definida positiva, entonces es invertible:

Dem.: (por método del absurdo)

repaso

Supongamos que el determinante de A es cero, y llegaremos a una solución absurda.

Si $\det(A) = 0$ y queremos resolver un sistema $Ax = 0$ significa que además de la solución trivial hay infinitas soluciones, es decir $\text{rango}(A) < n$, entonces

$$\exists \tilde{x} \neq 0 : A\tilde{x} = 0 \Rightarrow \tilde{x}^T A\tilde{x} = \tilde{x}^T 0 = 0$$

y entonces no se cumple que $\tilde{x}^T A\tilde{x} > 0$.

$$u. \left(\sum_{j \in \mathcal{O}_i} v_j v_j^T + \lambda I_k \right) = \sum_{j \in \mathcal{O}} r_{ij} v_j^T$$

$$u^* \in \left(\begin{matrix} A \\ A^{-1} \end{matrix} \right) A^{-1}$$

¿Por qué funciona la inversa? (2/2)

Demostremos que: $k \times k \rightarrow k \times k$

$A = x \cdot x^T + \lambda I_k$ es definida positiva, es decir, $y^T A y > 0, \forall y \in \mathbb{R}^k - \{0\}$
 $\lambda > 0$ (por el modelo)

Dem.: Sea $y \in \mathbb{R}^k - \{0\}$ A $\in \mathbb{R}$ (escalares)

$$y^T (x \cdot x^T + \lambda I_k) y = y^T x x^T y + y^T \lambda I_k y$$

(recordemos que el p.i. es $\langle u, v \rangle = u^T v$), prop. asociativa,

$$\langle u, v \rangle = \langle v, u \rangle$$
$$\langle y, x \rangle \langle x, y \rangle + \lambda \langle y, y \rangle = \langle x, y \rangle^2 + \lambda \|y\|^2 > 0.$$

$\therefore x \cdot x^T + \lambda I_k$ es definida positiva.

Proyección Ortogonal

Proyección

Sea \mathbb{V} un EV y $S \subset \mathbb{V}$ un SEV. Una transformación lineal $\Pi : \mathbb{V} \rightarrow \mathbb{S}$ es una proyección si $\Pi^2 = \Pi \circ \Pi = \Pi$

Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia: $\underbrace{[\Pi]^2}_{\text{matriz}} = \underbrace{[\Pi]}_{\text{matriz}}$. $[\Pi] \cdot [\Pi]$


Proyección Ortogonal

Dado \mathbb{V} un EV con p.i. y $S \subset \mathbb{V}$ un SEV, el objetivo es dado $v \in \mathbb{V}$ hallar $\tilde{v} \in S$ que sea “lo más parecido posible” a v .

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

Además vale que $\langle v - \tilde{v}, s \rangle = 0, \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



Teorema de proyección

Sea \mathbb{V} un EV de dimensión finita con p.i. $\langle \cdot, \cdot \rangle$, S un SEV. Dado $\underline{v} \in \mathbb{V}$ existe un único $\tilde{v} \in S$ tal que

$$\|v - \tilde{v}\| \leq \|v - u\|, \quad \forall u \in S$$

¿Cómo hallar la proyección?

Sea \mathbb{V} un EV de dimensión con p.i. $\langle \cdot, \cdot \rangle$, y $S \subset \mathbb{V}$ un SEV, $\dim(S) = m \geq 1$, y sea $B = \{s_1, \dots, s_m\}$ una BON de S . Buscamos encontrar la proyección de $\tilde{v} \in S$ de $\underline{v} \in \mathbb{V}$ ($\tilde{v} = \Pi_S(v)$).

Como $\tilde{v} \in S$, $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$ busco los coeficientes que minimizan $\|v - \sum_{i=1}^m \alpha_i s_i\|$. El problema puede escribirse como:

$$\|v - \tilde{v}\| \quad \Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha, \quad B = \begin{bmatrix} | & & | \\ s_1 & \dots & s_m \\ | & & | \end{bmatrix}, \quad \alpha = [\alpha_1, \dots, \alpha_m]^T$$

¿Cómo hallar la proyección?

Como por definición $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$, debo resolver el siguiente sistema de ecuaciones:

$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix} \cdot (v - B\alpha) = 0$$

base $\langle u, w \rangle = u^T w$ B^T

$$B^T(v - B\alpha) = 0 \Leftrightarrow B^T v = B^T B \alpha \Leftrightarrow \alpha = (B^T B)^{-1} B^T v$$

desp

$$P_{\Pi_S} = B(B^T B)^{-1} B^T$$

$$P_{\Pi_S}(v) = B(B^T B)^{-1} B^T v$$

Observación: Si B es una BON entonces $P_{\Pi_S} = BB^T$.

Aplicación: Cuadrados Mínimos

Supongamos que tenemos un sistema sobredeterminado *es decir, más ec. qe incógnitas* de la forma:

$$Ab = y, \quad A \in \mathbb{R}^{n \times m}, \quad b \in \mathbb{R}^m, \quad y \in \mathbb{R}^m, \quad m > n.$$

y es la solución de cuadrados mínimos

Como $m > n$, puede que no exista b que satisfaga todas las m ecuaciones, entonces busco la solución que más se acerque (busco $\text{Proy}_{\text{Col}(A)}y$)

$$b = \underline{(A^T A)^{-1} A^T} y \Rightarrow P = A(A^T A)^{-1} A^T$$


Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!

Ejemplo: ajustar una función por un polinomio

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función para un conjunto de puntos (x_1, \dots, x_n) a ajustar por un polinomio de grado k , $p(x) = c_0 + c_1x + \dots + c_kx^k$, $k \ll n$, c_i los coeficientes a ajustar.

Es decir, buscamos un polinomio que minimiza la suma de la diferencia de los cuadrados.

$$D^2 = \sum_{i=1}^n (f(x_i) - p(x_i))^2$$



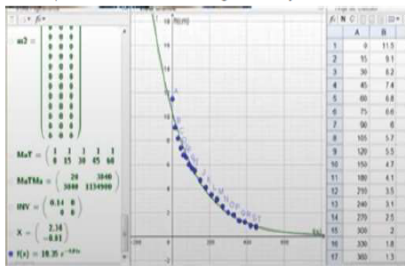
Si los datos no exhiben un comportamiento polinomial de grado k , el ajuste puede presentar oscilaciones, que requiera aumentar el grado. La matriz $A^T A$ puede estar mal condicionada al aumentar el grado.

Ejemplo básico: ajustar una función no polinomial

¿Cómo varía en el tiempo la altura de la espuma de la 🍺?

El estudio se basa en los siguientes ítems:

- Tipos de desintegración.
- Modelo funcional entre la desintegración y el tiempo.
- Relación entre el proceso de desintegración y la calidad de la cerveza.



$$f(x) = ae^{-bx}$$