

# Clase 7: Optimización

Verónica Pastor, Martín Errázquin


Análisis Matemático para Inteligencia Artificial

12/8/2022

# Ramas Principales de la Optimización




## Optimización con restricciones



Ptos críticos  
 $f(c)$  máx global  
 $f(a)$  min global

$f(x) \cdot \text{Dom } f \rightarrow \mathbb{R}$   
 $[a, b]$



$f(x) = x^3$



$f$  cont. en un  $[a, b]$

# Optimización con restricciones de igualdad

Dado el problema de optimización con restricciones:

$$\left. \begin{array}{l} \text{opt } f(x_1, \dots, x_n) \\ \text{s.a. } g_1(x_1, \dots, x_n) = 0 \\ \quad \vdots \\ g_m(x_1, \dots, x_n) = 0 \end{array} \right\} \quad (1)$$

donde  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  y  $g_i: \mathbb{R}^n \rightarrow \mathbb{R}$  con  $i = 1, \dots, m$ .

Se denomina **función Lagrangiana** a la función de  $n + m$  variables  $\mathcal{L}$  definida por:

*m restricciones*  
*↓*  
*∈ ℝ<sup>m</sup>*

$$\mathcal{L}(\bar{\lambda}, \bar{x}) = f(\bar{x}) + \lambda_1 g_1(\bar{x}) + \dots + \lambda_m g_m(\bar{x}), \quad \text{con } \bar{\lambda} = (\lambda_1, \dots, \lambda_m)$$

*(λ<sub>1</sub>, ..., λ<sub>m</sub>) · (g<sub>1</sub>, ..., g<sub>m</sub>)*  
*se puede plantear*  
*Ax = b*

## Multiplicadores de Lagrange

# Teorema de condición necesaria de Lagrange

Sea  $D \subseteq \mathbb{R}^n$  abierto. Sea (1) con  $m < n$ , donde  $f, g_i$   $i = 1, m$  son funciones definidas de  $D$  en  $\mathbb{R}$ , con derivadas parciales primeras continuas en  $D$  y

$$B = \{ \bar{x} \in D : g_i(\bar{x}) = 0, i = 1, m \}$$

el conjunto de soluciones factibles.

Entonces, si  $\bar{x}$  es un óptimo local de (1) tal que la matriz jacobiana de  $\bar{g}(\bar{x}^*)$  tal que  $|J\bar{g}(\bar{x}^*)_m| \neq 0$ , existen  $m$  números reales  $\lambda_1^*, \dots, \lambda_m^*$  tales que son solución del sistema:

$$J_{\bar{g}}(\bar{x}^*) = \begin{bmatrix} \nabla g_1 \\ \vdots \\ \nabla g_m \end{bmatrix} \quad \nabla f(\bar{x}^*) + \sum_{i=1, m} \lambda_i^* \nabla g_i(\bar{x}^*) = \bar{0} \quad \nabla f(\bar{x}^*) = - \sum \lambda_i^* \nabla g_i(\bar{x}^*)$$

Las soluciones factibles que verifican esta ecuación se denominan *puntos estacionarios*.

Los números  $\lambda_1, \dots, \lambda_m$  se denominan **multiplicadores de Lagrange** asociados a las  $m$  restricciones en el punto  $\bar{x}^*$ .

# Ejemplo


$$\min f(x_1, x_2) = x_1^2 + 2x_2$$

$$\text{s.a. } x_1 + x_2 = 1$$

$$x_1 + x_2 - 1 = 0$$

$$\rightarrow \underline{k_1} = x_1^2 + 2x_2 \Rightarrow x_2 = -\frac{x_1^2}{2}$$

parábola (\*)



Así definimos:

$$g(x_1, x_2) = x_1 + x_2 - 1.$$

- El conjunto de soluciones factibles es la recta  $x_2 = -x_1 + 1$ .
- Las curvas de nivel de la función  $f(x_1, x_2) = x_1^2 + 2x_2$  son parábolas de la forma  $x_1^2 + 2x_2 = k, k \in \mathbb{R}$ .

$$\therefore \bar{x}^* = (1, 0) \text{ y } f(\bar{x}^*) = 1.$$

Calculamos los vectores gradientes:  $\nabla f(x_1, x_2) = (2x_1, 2)$  y  $\nabla g(x_1, x_2) = (1, 1)$ , ambos vectores son l.d. en  $\bar{x}^*$ .

$$\begin{aligned} \text{Planteo } \nabla f &= -\lambda \nabla g \\ (2x_1, 2) &= -\lambda(1, 1) \\ 2x_1 &= -\lambda \\ 2 &= -\lambda \end{aligned}$$

# Optimización con restricciones de desigualdad

## Condiciones necesarias de primer orden de Fritz-John

Dado el problema de optimización con restricciones:

$$\begin{array}{ll} \text{opt } f(x_1, \dots, x_n) \\ \text{s.a. } \left. \begin{array}{l} g_1(x_1, \dots, x_n) \leq 0 \\ \vdots \\ g_m(x_1, \dots, x_n) \leq 0 \end{array} \right\} & (2) \end{array}$$

donde  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  y  $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$  con  $i = 1, \dots, m$ . Sea  $\bar{x}^*$  un punto tal que  $I = \{i : \underline{g_i(\bar{x}^*)} = 0\}$ ,  $f, g_i$  diferenciables en  $\bar{x}^*$ . Entonces, si  $g_i, i \notin I$  son continuas en  $x^*$  se verifica que es solución y existen escalares  $\lambda_0, \lambda_i, i \in I$  no todos nulos tales que:

$$\lambda_0 \nabla f(\bar{x}^*) + \sum_{i=1, m} \lambda_i \nabla g_i(\bar{x}^*) = \bar{0}$$

para  $0 \leq \lambda_0, \lambda_i, i \in I$ , y  $g_i(\bar{x}^*) \leq 0, i = 1, m$ .



# Dualidad en Optimización: Problema dual

Dado el problema primal:

$$\min f(x_1, \dots, x_n)$$

$$\text{s.a. } g(x_1, \dots, x_n) \leq b$$

$$x_i \geq 0$$

Tenemos el problema dual:

$$\max D(y_1, \dots, y_m)$$

$$\text{s.a. } h(y_1, \dots, y_m) \geq b$$

$$y_j \leq 0$$


- Si  $\bar{x}^*$  es una solución factible del problema primal e  $\bar{y}^*$  es una solución del dual entonces  $\underline{f(\bar{x}^*)} \geq \underline{D(\bar{y}^*)}$ .
- Si un problema no tiene un óptimo finito entonces el otro no es factible.

# Función Convexa

**Def:** Un subconjunto  $S \subset \mathbb{R}^n$  es convexo si para cada par de puntos  $x, y \in S, \alpha \in [0, 1]$  se verifica que  $z = \alpha x + (1 - \alpha)y \in S$ .

Obs:  $X_1, X_2$  son dos conjuntos convexos, entonces,

- $X_1 \cap X_2$  es convexo.
- $X_1 + X_2 = \{x_1 + x_2 \in \mathbb{R}^n : x_1 \in X_1, x_2 \in X_2\}$ .
- si  $L$  es una transformación lineal,  $L(X_1)$  es convexa.



## Función Convexa

**Def:** Sea  $M \subset \mathbb{R}^n, M \neq \emptyset$  convexo,  $f : M \rightarrow \mathbb{R}$ . Entonces se dice que:

- $f$  es convexa en  $M$  sii  $\forall x, y \in M, \forall \alpha \in [0, 1]$  se verifica que:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$$

## Desigualdad de Jensen

- $f$  es estrictamente convexa en  $M$  sii  $\forall x, y \in M, \forall \alpha \in (0, 1)$  se verifica que:

$$f(\alpha x + (1 - \alpha)y) < \alpha f(x) + (1 - \alpha)f(y)$$

# Condiciones para convexidad de funciones diferenciables

Sea  $M \subset \mathbb{R}^n$ ,  $M \neq \emptyset$  abierto convexo,  $f : M \rightarrow \mathbb{R}$  diferenciable, se dice que:  
 $f$  es convexa en  $M \Leftrightarrow \forall x, y \in M, f(y) \geq f(x) + \nabla f(x)(y - x)$

O bien,  $(\nabla f(y) - \nabla f(x))(y - x) \geq 0$  *análogos* *con derivadas segundas continuas.*

**Prop:** Sea  $M \subset \mathbb{R}^n$ ,  $M \neq \emptyset$  abierto convexo,  $f : M \rightarrow \mathbb{R}$   $f \in \mathcal{C}^2$ . Entonces,  $f$  es convexa en  $M$  si  $\forall x \in M, y^T Hf(x)y \geq 0$ , para cualquier  $y \in \mathbb{R}^n$ .

**Condiciones Suficientes de Optimalidad Global** *matriz Hessiana es simétrica ( $\mathcal{C}^2$ )*

$$\begin{aligned} & \text{opt } f(x_1, \dots, x_n) \\ & \text{s.a. } g_1(x_1, \dots, x_n) = 0 \quad \therefore Hf \text{ es def. positiva} \\ & \vdots \\ & g_m(x_1, \dots, x_n) = 0 \end{aligned}$$

con  $m < n$  donde  $f$  y  $g_i, i = 1, \dots, m$  son funciones  $\mathcal{C}^1$  en un conjunto abierto  $D \in \mathbb{R}^n$ . Entonces se verifica que si  $f$  es convexa en el conjunto de soluciones factibles  $B$  y, las funciones  $g_i$  son lineales, todos los puntos estacionarios son mínimos globales.

# Programación Lineal

Un problema de programación lineal es donde tanto la función objetivo como las funciones que definen las restricciones son lineales. La forma general es:

$$\begin{array}{l} \text{función objetivo} \\ \text{opt } c_1x_1 + \dots + c_nx_n \\ \\ \text{restricciones} \left\{ \begin{array}{l} \text{s.a. } a_{11}x_1 + \dots + a_{1n}x_n \leq b_1 \\ \vdots \\ a_{m1}x_1 + \dots + a_{mn}x_n \leq b_m \\ d_{11}x_1 + \dots + d_{1n}x_n \geq e_1 \\ \vdots \\ d_{r1}x_1 + \dots + d_{rn}x_n \geq e_r \\ g_{11}x_1 + \dots + g_{1n}x_n = b_1 \\ \vdots \\ g_{s1}x_1 + \dots + g_{sn}x_n = b_s \end{array} \right. \end{array}$$

# Propiedades de la Programación Lineal

**Definición:** Sea  $S \subset \mathbb{R}^n$  convexo  $S \neq \emptyset$ ,  $\bar{x}^* \in S$  es un punto extremo de  $S$  si  $\bar{x}^*$  no puede expresarse como combinación lineal convexa de puntos de  $S$  distintos de él.

- 1 Es un problema convexo ya sea de minimización o maximización.
- 2 La solución óptima, si existe, es global.
- 3 Nunca existen óptimos locales que no sean globales.
- 4 Puede tener o no solución, en caso de existir se encuentra en único punto o en infinitos.



**Objetivo:** Se busca hallar  $\min \bar{c}\bar{x}$ , s.a.  $A\bar{x} = \bar{b}; \bar{x} \geq 0$ ,

donde  $A \in \mathbb{R}^{m \times n}$ ,  $m < n$ ,  $\text{rg}(A) = m$ .


$\rightarrow$  rango de  $A$  es siempre mayor o igual a 0 y menor o igual al  $\min\{m, n\}$   
tengo  $m$  restricciones l.i.

$$g_1 \rightarrow a_{11}x_1 + \dots + a_{1n}x_n \leq b_1$$

$\vdots$


$$g_m \rightarrow a_{m1}x_1 + \dots + a_{mn}x_n = b_m$$

# Algoritmo del simplex

 **Iniciar:** eligiendo una solución básica factible de una submatriz  $B$  de  $A$ ,  $|B| \neq 0$ . **Iterar:**

- 1 Resolver el sistema  $B\bar{x}_B = \bar{b}$ . Entonces la solución será  $\bar{x} = (\bar{x}_B, \bar{x}_N)$ .
- 2 Calcular  $Y = B^{-1}N$ , donde  $N \in \mathbb{R}^{m \times (n-m)}$  cuyas columnas corresponden a las soluciones no básicas. Hallar  $z_j = \bar{c}_B \bar{y}_j$ , donde  $\bar{c}_B$  son los coeficientes de la función objetivo asociados a la solución básica e  $\bar{y}_j$  es la columna de la matriz  $T$  correspondiente a  $x_j$ .

Sea  $z_k - c_k = \max\{z_j - c_j, j \in J\}$  donde  $J$  los índices asociados a las variables no básicas. ✓

- Si  $z_k - c_k \leq 0$ , la solución básica factible es el óptimo del problema, que no será único si  $z_k - c_k = 0$
  - Si  $z_k - c_k > 0$  debemos seguir... 
- 3 Antes de construir una nueva solución conviene ver si existe  $j \in J : z_k - c_k > 0, \bar{y}_j \leq 0$ . Si esto no sucede, terminamos ya que el problema carece de óptimo finito. Sino, construimos una nueva solución:

La variable  $x_k$  correspondiente al  $z_k - c_k$  máximo, será básica en la nueva solución y dejará de serlo  $x_l$ , cuando  $l$  sea el índice determinado por:

$$\frac{x_l}{y_{lk}} = \min\left\{\frac{x_i}{y_{ik}} : y_{ik} > 0\right\}$$

Actualizar la nueva submatriz  $B$  y volver a (1).

# Programación cuadrática

En el caso de que la función objetivo sea una cuadrática convexa:

$$\min_{x \in \mathbb{R}^d} \underbrace{\frac{1}{2} x^T Q x + c^T x}$$

s.a:  $Ax \leq b$  donde  $A \in \mathbb{R}^{m \times d}$ ,  $b \in \mathbb{R}^m$ ,  $c \in \mathbb{R}^d$ .  
 $\xrightarrow{\text{g.c.}} \boxed{Ax - b \leq 0}$

La matriz  $Q \in \mathbb{R}^{d \times d}$  es simétrica y definida positiva, y por lo tanto la función objetivo es convexa. El lagrangiano está dado por:

$$L(x, \lambda) = \underbrace{\frac{1}{2} x^T Q x + c^T x} + \underbrace{\lambda^T (Ax - b)}$$

Derivando respecto a  $x$ , y despejando:

$$Qx + (c + A^T \lambda) = 0 \Rightarrow \boxed{x = -Q^{-1}(c + A^T \lambda)}$$

Y substituyendo obtenemos la lagrangiana dual:

$$\underbrace{D(\lambda)} = -\frac{1}{2} \underbrace{(c + A^T \lambda)^T Q^{-1} (c + A^T \lambda)} - \lambda^T b.$$

# Convexo Conjugado

La **transformada de Legendre-Fenchel** es una transformación de una función convexa diferenciable  $f(x)$  a una función que depende de las tangentes  $s(x) = \nabla_x f(x)$ .

Se define el conjugado convexo de una función  $f : \mathbb{R}^D \rightarrow \mathbb{R}$  es una función  $f^*$  definida por:

$$f^*(s) = \sup_{\underline{x \in \mathbb{R}^D}} (\underbrace{\langle x, s \rangle}_{\text{prod. escalar}}, \underbrace{f(x)}_{\text{p.i.}})$$

↳ p.i., podría considerarse el prod. escalar

Bağetes en python

CVXPY → optimización convexa  
PULP → Prog. lineal y cuadr.

Python Repository, common optimizer → In[ ]: